HW2 多元線性回歸

修訂版：雙題目與自訂 Dataset

學號：5113056021

本版依 2026-11-02 提供的新作業說明製作，以加總分 2 分的兩項功能為目標。主要交付為 GitHub 原始碼與可操作網站；本 PDF 補充網站方法與結果，原始洪水完整報告另附。

加分要求	本版實作
加總分 1 分：下拉呈現兩種 problem	洪水分數（20 特徵）與 King County 房價（18 特徵）
加總分 2 分：任意輸入 Dataset	公開 CSV URL / 檔案上傳；自選 Target 與排除欄位；實際重新訓練
主要分析要求	LinearRegression、訓練集特徵選擇、獨立測試評估與 95% 區間圖
AI 研究標示	GPT 輔助內容與既有 NotebookLM 摘要分別標示

GitHub：https://github.com/HitomiHuang/HW2_MULTIPLE_LINEAR_REGRESSION

網站：https://hw2-regression-lab-5113056021.ivy819.chatgpt.site

操作方式：切換 Problem；或展開自訂 Dataset、載入 CSV、選 Target，再按「執行回歸分析」。首次 Python 套件載入需網路；網站示範結果可立即查看。

本版不保證評分結果；實際加分依教師驗收認定。

01 / Business Understanding

洪水題目：使用 20 個環境與管理分數預測 FloodProbability，評估線性模型能否擷取合成分數規律。資料為合成資料，不推論為真實洪災機率，不能作為防災警報。

房價題目：使用房屋條件、區位與周邊房產資訊預測 King County 2014–2015 年成交價 price，單位美元。這是歷史資料練習，不是目前市場估價。

02 / Data Understanding

資料集	來源筆數	原始輸入特徵	Target
Kaggle S4E5 洪水	1,117,957	20	FloodProbability
King County 房價	21,613	18	price
50 Startups（自訂範例）	50	4	Profit

特徵數不包含目標、索引、ID、日期；兩個主要題目都落在 14–39 範圍。50 Startups 只有 4 個原始特徵，僅作為老師指定 URL 的加分功能驗收，不充當主要題目。房價的原始檔含額外 CSV 索引，已移除。

洪水來源：https://www.kaggle.com/competitions/playground-series-s4e5/data

房價來源：https://www.kaggle.com/datasets/harlfoxem/housesalesprediction

房價取得鏡像：https://raw.githubusercontent.com/rheera/data-analysis-with-python/main/kc_house_data.csv

03 / Data Preparation

網站固定 seed = 42，兩題各抽取 4,000 筆；分為訓練 2,400、校準 800、測試 800 筆。數值補值採訓練折中位數並標準化；類別採眾數補值與 one-hot，未知類別忽略。所有 fit 與特徵選擇均在交叉驗證的訓練折內。

自訂 CSV 以使用者選定 Target 建模，移除無效或缺失目標；原始特徵上限 100、編碼後上限 300、文字類別上限 40，較高基數或全空欄位會明示排除。互動版檔案最多 10 MB，可選分析 1,000 / 4,000 / 10,000 筆上限。

04 / Modeling 與 Feature Selection

比較平均值基線、全特徵 sklearn.linear_model.LinearRegression 與 SelectKBest + LinearRegression。以訓練集五折 KFold CV 比較保留 1 欄、50%、75%、100% 編碼特徵，依平均 CV RMSE 選擇設定。若類別數隨折改變，保留欄數依該訓練折維度向上取整。

特徵選擇不必然刪欄。兩題在本次抽樣與候選設定中，都以保留全部特徵的 CV RMSE 最小；這是實際選模結果，並未為了呈現刪欄而使用測試集挑選設定。

洪水題目：訓練集五折 CV

比例	完整訓練集保留欄數	平均 RMSE	折間 SD
5.0%	1	0.0492594	0.00182912
50.0%	10	0.0391426	0.000893658
75.0%	15	0.0320681	0.000823564
100.0%	20	0.0199308	0.000820978

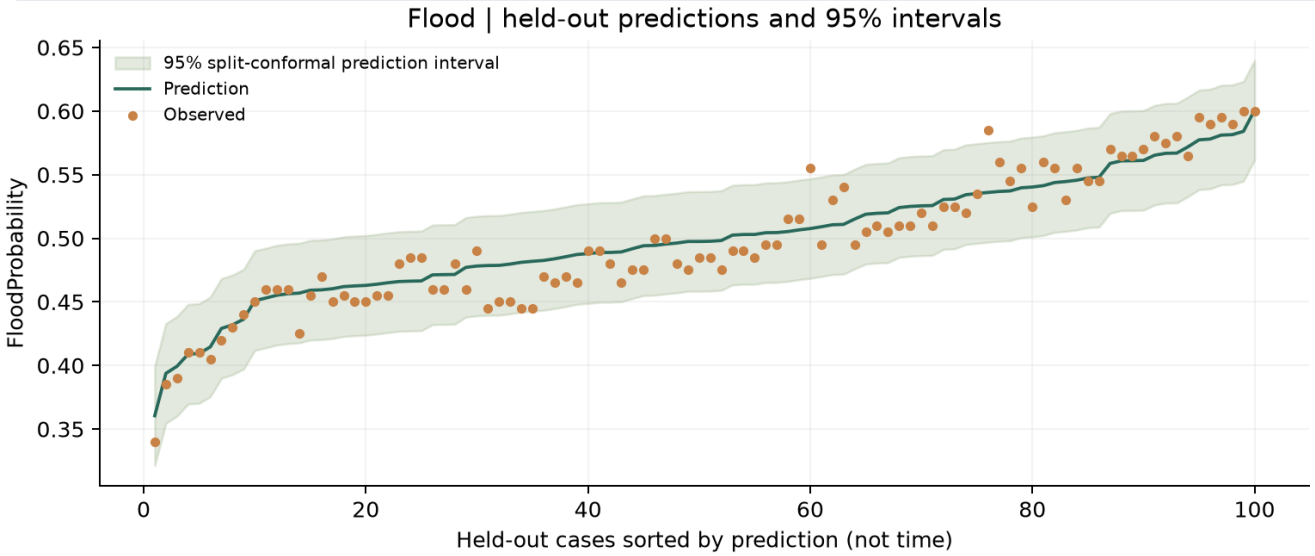
房價題目：訓練集五折 CV

比例	完整訓練集保留欄數	平均 RMSE	折間 SD
5.6%	1	277412	20128.6
50.0%	9	243289	19009.9
75.0%	14	221926	19625.8
100.0%	18	211276	21530.5

係數以標準化數值特徵與類別虛擬變數為基礎，代表條件關聯，不能解讀成因果效果。房價 zipcode 在此基線採數值表示，不能視為郵遞區號有真實距離順序；可在後續模型改為適當的區域編碼。

05 / Evaluation：洪水題目

模型	RMSE	MAE	R^2
平均值基線	0.053731	0.043155	-0.000047
全特徵 LinearRegression	0.020139	0.015908	0.859509
特徵選擇 LinearRegression	0.020139	0.015908	0.859509



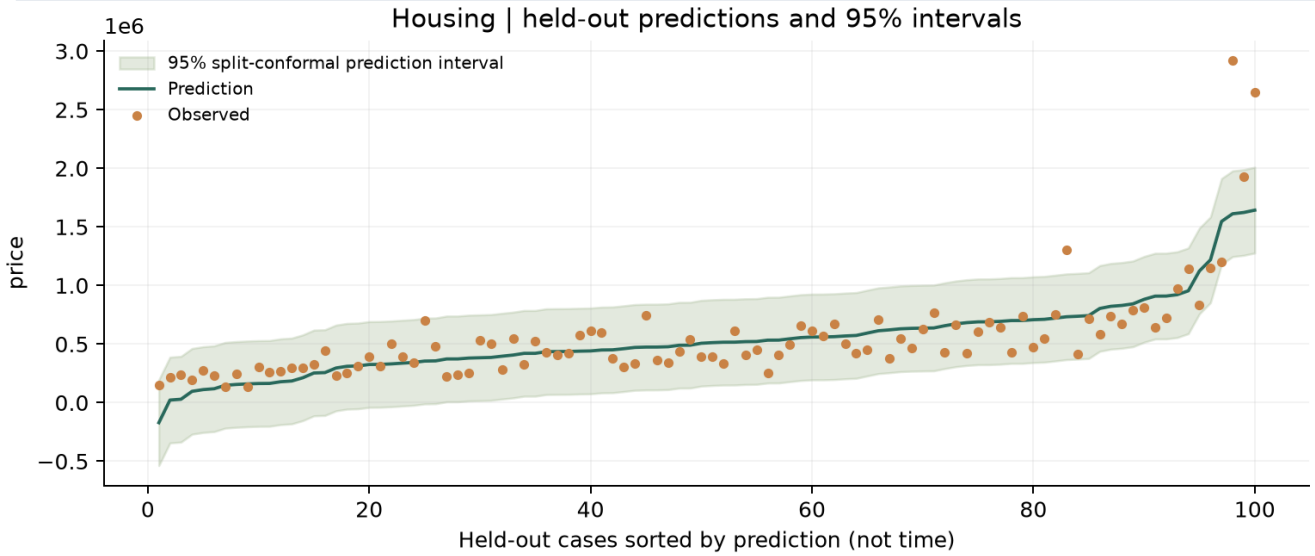
選入 20 / 20 個編碼特徵。測試 MSE = 0.00040558；調整 R^2 = 0.855902。95% conformal 區間實測覆蓋率 94.625%，平均寬度 0.078333。

區間以獨立校準集 800 筆絕對殘差排序，取 ceil((800+1) × 0.95) = 761 順位；覆蓋率使用全部 800 筆測試資料計算。圖僅呈現最多 100 筆固定抽樣案例，依預測值排序，並非時間序列。

原始洪水完整報告另以 50,000 筆樣本及 64/16/20 分割，RMSE 0.020046、R^2 0.843466；網站的 4,000 筆與 60/20/20 分割因此呈現不同數值，兩者不混用。

05 / Evaluation：King County 房價

模型	RMSE（USD）	MAE（USD）	R^2
平均值基線	378,547.31	233,396.76	-0.000059
全特徵 LinearRegression	214,640.38	130,199.54	0.678480
特徵選擇 LinearRegression	214,640.38	130,199.54	0.678480



選入 18 / 18 個編碼特徵。測試 MSE = 46,070,492,488.41 USD^2；調整 R^2 = 0.671070。95% conformal 區間實測覆蓋率 96.375%，平均寬度 731,710.03 USD。

房價有偏態與高價離群值，線性模型的誤差及區間較大。sqft_living = sqft_above + sqft_basement 造成精確共線性；程式辨識矩陣秩不足並明示，採 SVD 最小範數解。個別共線係數無唯一解，不強行詮釋其效果。

主要採 conformal 區間，不裁切負下界。其邊際覆蓋保證需要校準與新資料可交換，不保證每個價位子群都有 95% 覆蓋。隨機切分可能包含同一房產或鄰近房產，跨年份、跨地區評估需另做時間或群組切分。

區間、假設與自訂資料驗證

網頁可切換三種 95% 區間：split-conformal 單筆預測區間、OLS 平均反應信賴區間、OLS 單筆預測區間。OLS 區間以設計矩陣 SVD 偽逆計算 leverage，t 分布自由度為訓練筆數減矩陣秩；選模後未另校正選擇不確定性，故列為參考。

五項假設：線性與等變異透過殘差圖檢視；常態透過 Q-Q 圖及 Jarque–Bera；共線性透過矩陣秩；獨立性依資料蒐集過程判斷，隨機列序不適合用 Durbin–Watson 當作時間獨立性的證據。此版沒有宣稱所有假設都通過。

50 Startups 實測結果

老師指定的公開 CSV 網址可直接載入，Target = Profit。4 個原始特徵含 State 類別，編碼後 5 欄。五折 CV 選出 1 欄；測試 RMSE 7702.2053、R^2 0.926742。

小樣本修正：若僅留 10 筆校準，ceil((10+1) × 0.95)=11 超過可用殘差，無法給有限區間。因此至少保留 19 筆校準，本例訓練 21 / 校準 19 / 測試 10，取最大校準殘差為半寬。10 筆測試的覆蓋率變動很大，不宣稱穩定泛化。

06 / Deployment

以 buildless HTML/CSS/JS 發布，Python/scikit-learn 經 Pyodide 在 Web Worker 內執行。內建題目先顯示與同一程式產生的示範結果；按下執行後會真的重新訓練。自訂資料不送至網站伺服器；URL 下載須允許 CORS，限制時改用上傳。結果 JSON 含設定、分割列號、CV、係數、逐筆區間與來源。

程式驗證涵蓋：獨立重算 RMSE、R^2、覆蓋率；三份資料分割不重疊；修改測試標籤不影響選模、係數與區間半寬；修改校準標籤只影響區間；缺失值處理與不合法目標；兩題及 50 Startups 實例。

GPT 輔助內容

GPT 協助查找公開資料、撰寫與調整 Python、網站互動、特徵選擇流程、區間公式、圖表、測試、報告及 GitHub/網站部署。分析數值由實際程式執行，不是由語言模型臆測。原有報告保留較完整的洪水模型比較，本補充報告交代新增功能與第二題。

NotebookLM 摘要

以下沿用 2026-10-20 已實際完成並保存的 NotebookLM 洪水研究；不是本次新產生的 NotebookLM 回覆，也未用它宣稱房價結果。原始兩輪問答、摘要、來源與截圖均保留。摘要超過 100 個中文字。

Kaggle 洪水分數競賽官方說明，其資料集是由深度學習模型基於「原始資料集」生成的合成資料，分佈僅接近原始資料，非已驗證的真實觀測。〔N1〕Kaggle 討論中，參賽者提出「20 個特徵為等價偽隨機數」之假說，據此建議採用無視順序的列總和與跨欄排序進行對稱特徵工程。〔N2〕

在特徵選擇方面，SelectKBest 依單變量統計檢定篩選，RFE 則依模型權重遞歸剔除〔N3〕；若特徵等價假說成立，特徵選擇未必需要刪欄。〔N2〕為避免資料洩漏，必須嚴格切分訓練與測試集，並透過 scikit-learn 的 Pipeline 將預處理與模型串接，確保 fit 僅作用於訓練集。〔N4〕

估計不確定性時，statsmodels 的 get_prediction 可計算平均反應信賴區間（含模型參數誤差）與單一新觀測預測區間（多含個體隨機誤差而更寬）。〔N5〕若導入符合性預測（Conformal Prediction），其統計保證需滿足校準與新資料的可交換性，以提供無分佈假設的邊際覆蓋。〔N6〕

研究筆記本：https://notebook.google.com/notebook/11cff97a-cbaa-4e58-8eca-b6541d1b25e2

[N1] Kaggle S4E5：官方資料說明：https://www.kaggle.com/competitions/playground-series-s4e5/data

[N2] Kaggle：Sorting along the feature axis as feature engineering：https://www.kaggle.com/competitions/playground-series-s4e5/discussion/499579

[N3] scikit-learn：Feature selection：https://scikit-learn.org/stable/modules/feature_selection.html

[N4] scikit-learn：Common pitfalls and recommended practices：https://scikit-learn.org/stable/common_pitfalls.html

[N5] statsmodels：OLSResults.get_prediction：https://www.statsmodels.org/stable/generated/statsmodels.regression.linear_model.OLSResults.get_prediction.html

[N6] Angelopoulos and Bates：A Gentle Introduction to Conformal Prediction：https://arxiv.org/abs/2107.07511

GPT 對話 PDF 收錄既有 ChatGPT 網頁問答；另輸出目前可取得的歷次保存文字與本次更新對話，範圍截至匯出時點。未取得的其他聊天不宣稱完整。