多元線性回歸
整合分析報告

Regression Lab

以洪水合成分數與 King County 房價為例，整合資料理解、特徵選擇、線性回歸、獨立測試評估與預測區間，並提供可操作的 GitHub Pages 網站。

分析主題	原始特徵	測試 R^2	95% PI 實測覆蓋
洪水風險分數	20	0.859509	94.625%
King County 房價	18	0.678480	96.375%

網站：https://hitomihuang.github.io/HW2_MULTIPLE_LINEAR_REGRESSION/

GitHub：https://github.com/HitomiHuang/HW2_MULTIPLE_LINEAR_REGRESSION

內容包含：資訊圖表、CRISP-DM 分析、模型評估與區間圖、GPT 輔助內容、NotebookLM 摘要，以及 ChatGPT 技術問答截圖。

本報告以網站使用的每題 4,000 筆樣本為主要結果。既有 50,000 筆洪水實驗屬不同資料範圍，其指標不與本報告混用。

內容索引

內容索引 2

資訊圖表｜從資料到預測 3

01 / 問題定義與資料理解 4

02 / 資料準備與建模 5

03 / Evaluation：洪水 6

03 / Evaluation：房價 7

04 / 預測區間與模型診斷 8

05 / Deployment 與自訂資料 9

06 / GPT 輔助內容 10

07 / NotebookLM 摘要 11

參考來源與重現資料 12

ChatGPT 技術問答 G1｜CRISP-DM 與資料洩漏 13

ChatGPT 技術問答 G2｜特徵選擇與交叉驗證 14

ChatGPT 技術問答 G3｜95% 區間與小樣本校準 15

ChatGPT 技術問答 G4｜實驗結果與回歸假設 16

ChatGPT 技術問答 G5｜獨立性與群組泛化評估 17

ChatGPT 技術問答 G6｜GitHub Pages 部署與可重現性 18

閱讀方式：先看資訊圖表與兩個題目的評估結果，再查看分析方法與 AI 研究；本次 ChatGPT 技術問答截圖集中於文末。

資訊圖表｜從資料到預測

洪水風險分數

20 個輸入特徵
Target：FloodProbability
合成分數；非真實災害警報

King County 房價

18 個輸入特徵
Target：price（美元）
2014–2015 年歷史交易

每個題目 4,000 筆 | seed = 42

訓練 2,400（60%） | 校準 800（20%） | 測試 800（20%）

01 問題定義

定義數值預測目標與使用限制

02 資料理解

確認來源、輸入特徵與缺失情形

03 資料準備

先切分；補值與編碼只 fit 訓練折

04 建模選擇

五折 CV + SelectKBest + 線性回歸

05 模型評估

獨立測試誤差與 95% 預測區間

06 網站部署

GitHub Pages；自訂 CSV 與結果匯出

洪水模型結果

測試 $R^2 = 0.8595$
RMSE = 0.020139 （合成分數）
95% PI 實測覆蓋率 94.625%

房價模型結果

測試 $R^2 = 0.6785$
RMSE = 214,640.38 USD
95% PI 實測覆蓋率 96.375%

每題測試 800 筆。RMSE 的單位不同，兩題不直接比較。95% conformal 區間需要校準與新資料可交換的前提；實測覆蓋不是每個子群的保證。

GPT 輔助內容〔G1、G3、G4、G6〕

01 / 問題定義與資料理解

Business Understanding

洪水題目：以 20 個環境與管理分數預測 FloodProbability，研究線性模型是否能擷取合成資料中的規律。此分數未經驗證為真實洪災發生機率，不能作為防災警報。 [D1]

房價題目：以房屋條件、區位與鄰近房產資訊預測 King County 2014–2015 年歷史成交價 price，單位美元；這是歷史交易建模，不代表目前市場估價。 [D2]

Data Understanding

資料集	來源筆數	原始輸入特徵	Target
Kaggle S4E5 洪水	1,117,957	20	FloodProbability
King County 房價	21,613	18	price
50 Startups 範例	50	4	Profit

輸入特徵數不包含 Target、索引、ID 與日期。房價鏡像含額外 CSV 索引，抽樣前移除；兩個內建題目各固定抽取 4,000 筆。50 Startups 僅作自訂 CSV 範例，含 State 類別欄位。 [D3]

洪水樣本 SHA-256：8cb2ee2883f664cdd886872a31e126bbae21c0132618636634446a643d18f231

房價樣本 SHA-256：3a296fdb2b5c7d1d6858df59c16764b4b27ea61801e7a13bbfd60fb3f844b070

資料限制：洪水為合成分數；房價可能有同一房產重複交易、空間依賴與時間差異。來源的資料生成或蒐集背景，會限制可作出的推論。

GPT 輔助內容〔G1、G4、G5〕；NotebookLM 摘要〔N1、N7、N9〕

02 / 資料準備與建模

Data Preparation

固定 seed = 42，每題切為訓練 2,400、校準 800、測試 800。先分割再處理：數值欄以訓練折中位數補值、標準化；類別欄以訓練折眾數補值與 one-hot 編碼。未知類別採忽略處理，預處理與特徵選擇放在 Pipeline 內，測試標籤不參與選模。 [M1]

GPT 輔助內容〔G1、G2〕；NotebookLM 摘要〔N3、N4、N8〕

Modeling 與 Feature Selection

比較平均值基線、全特徵 LinearRegression，以及 SelectKBest + LinearRegression。訓練集五折 CV 比較保留 1 欄、50%、75% 與全部編碼特徵，依平均 CV RMSE 選擇。類別數可能隨折改變，因此保留欄數按各訓練折維度計算。 [M2]

洪水：CV RMSE，單位合成分數

保留比例	最終欄數	平均 CV RMSE	折間 SD
5.0%	1	0.0492594	0.00182912
50.0%	10	0.0391426	0.000893658
75.0%	15	0.0320681	0.000823564
100.0%	20	0.0199308	0.000820978

房價：CV RMSE，單位美元

保留比例	最終欄數	平均 CV RMSE	折間 SD
5.6%	1	277412	20128.6
50.0%	9	243289	19009.9
75.0%	14	221926	19625.8
100.0%	18	211276	21530.5

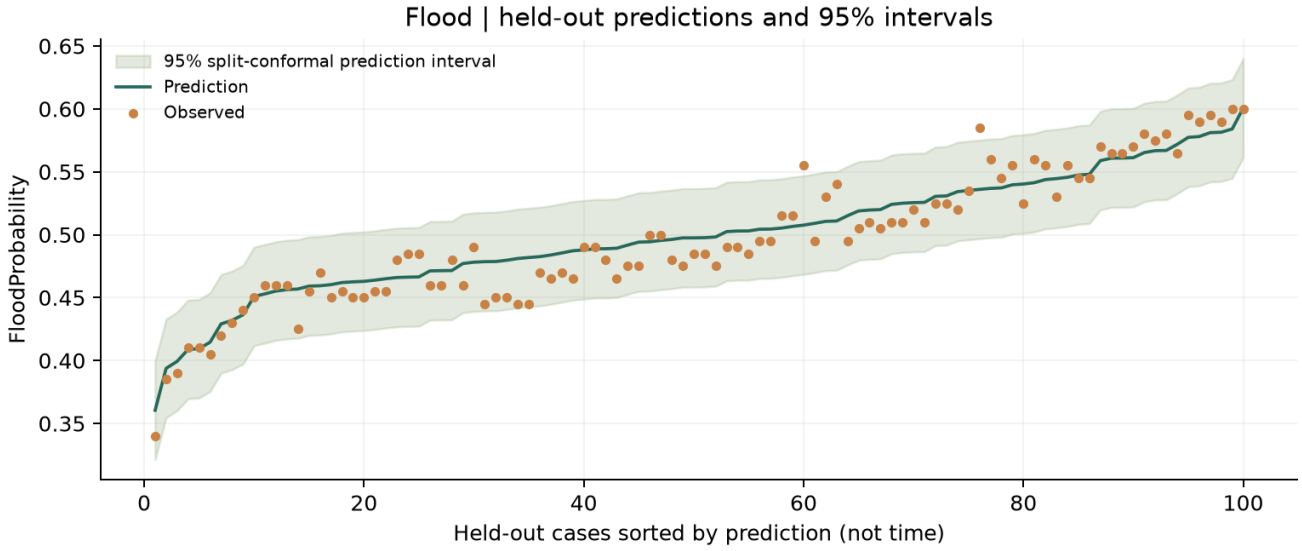
本次候選設定中，兩題都由 CV 選出保留全部特徵。特徵選擇不必然刪欄；本報告如實保留此結果，未依測試集挑選設定。

GPT 輔助內容〔G2〕

03 / Evaluation：洪水

模型	MAE	RMSE	R^2
平均值基線	0.043155	0.053731	-0.000047
全特徵 LinearRegression	0.015908	0.020139	0.859509
特徵選擇 LinearRegression	0.015908	0.020139	0.859509

MAE 與 RMSE 單位：合成分數；測試 800 筆。



圖：100 筆固定抽樣測試案例，按預測值排序，橫軸不是時間。綠線為預測，橘點為實際值，陰影為 95% split-conformal 預測區間。完整覆蓋率使用全部 800 筆測試資料計算。

選入 20 / 20 欄。測試 MSE = 0.00040558。調整 R^2 = 0.855902；95% 區間實測覆蓋率 94.625%，平均寬度 0.078333 合成分數。

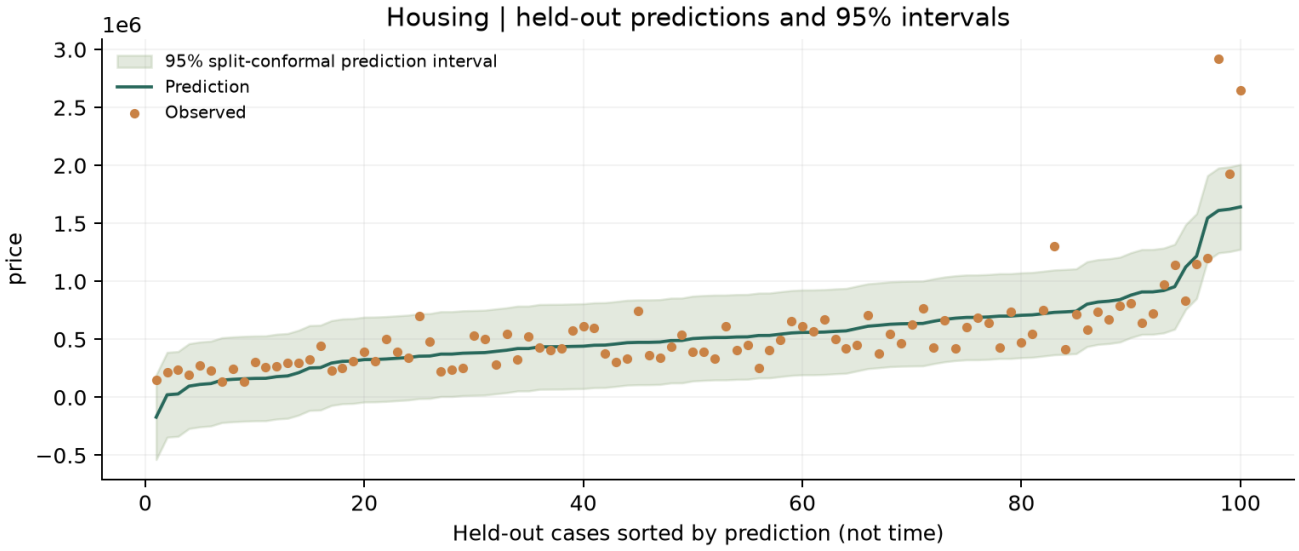
相較平均值基線，線性回歸降低測試誤差；仍有未被線性模型解釋的雜訊與偏差。這些結果描述本次相似分布樣本，不應直接推廣至真實洪災決策。

GPT 輔助內容〔G4〕

03 / Evaluation：房價

模型	MAE	RMSE	R^2
平均值基線	233,396.76	378,547.31	-0.000059
全特徵 LinearRegression	130,199.54	214,640.38	0.678480
特徵選擇 LinearRegression	130,199.54	214,640.38	0.678480

MAE 與 RMSE 單位：USD；測試 800 筆。



圖：100 筆固定抽樣測試案例，按預測值排序，橫軸不是時間。綠線為預測，橘點為實際值，陰影為 95% split-conformal 預測區間。完整覆蓋率使用全部 800 筆測試資料計算。

選入 18 / 18 欄。測試 MSE = 46070492488.41064453 USD^2。調整 R^2 = 0.671070；95% 區間實測覆蓋率 96.375%，平均寬度 731710.033514 USD。

房價偏態與高價離群值使誤差及區間較大。sqft_living = sqft_above + sqft_basement 造成精確共線性，模型採 SVD 最小範數解，個別共線係數不具唯一解。zipcode 的數值表示也是此基線的簡化。跨年份或地區部署需重新評估。

GPT 輔助內容〔G4〕

04 / 預測區間與模型診斷

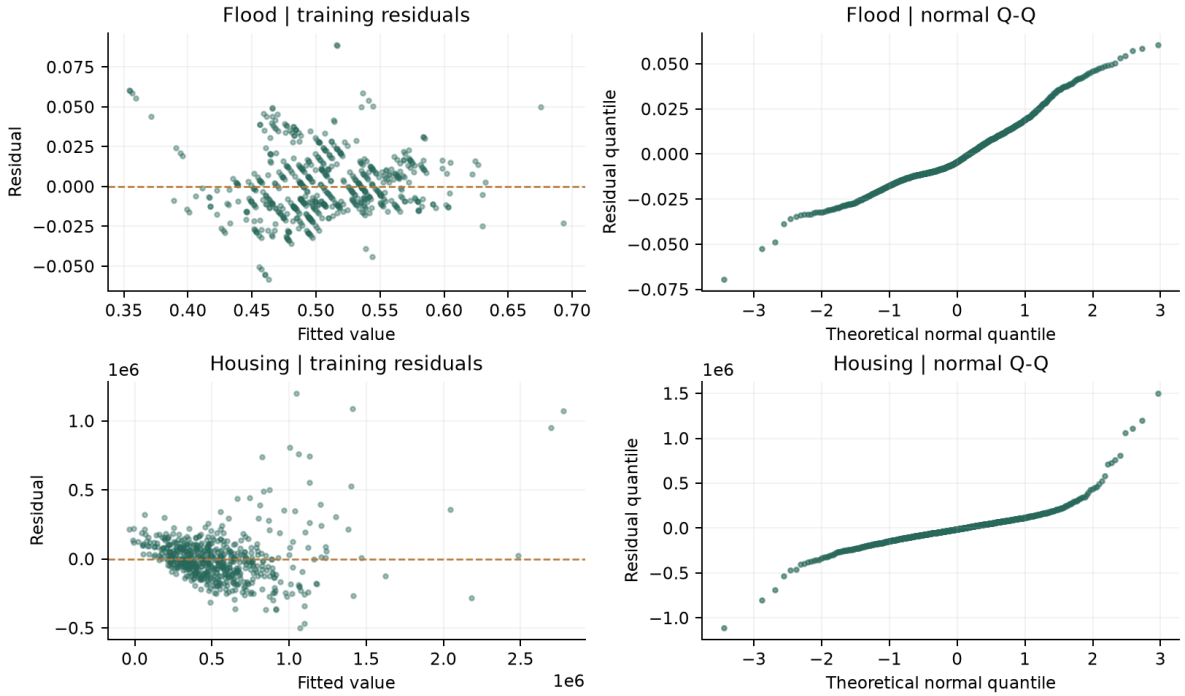
主要區間：95% split-conformal

用獨立校準集的絕對殘差取第 ceil((n_cal + 1) × 0.95) 順位為半寬。800 筆校準取第 761 順位；測試集只評估覆蓋率與誤差，不決定半寬。其邊際覆蓋需要校準與新資料可交換，並不保證每個價位或地區子群都達 95%。區間未裁切上下界。 [M4]

OLS 平均反應信賴區間與單筆預測區間

網站另提供 95% OLS mean CI 與 observation PI，以設計矩陣 SVD 偽逆求 leverage，自由度為訓練筆數減矩陣秩。單筆 PI 多含新觀測的隨機誤差，通常較寬。OLS 區間需額外假設，且未校正選模不確定性，作為參考。 [M3]

GPT 輔助內容〔G3〕；NotebookLM 摘要〔N6、N9〕



上排洪水、下排房價；左圖為訓練殘差，右圖為常態 Q-Q。圖使用固定間隔取出的訓練點。

診斷	洪水	房價
Jarque–Bera p	3.23e-43	小於浮點數顯示範圍
設計矩陣秩 / 欄數	21 / 21	18 / 19
殘差自由度	2,379	2,382

線性與等變異以殘差圖檢視；常態以 Q-Q 與 Jarque–Bera 檢視；共線性以矩陣秩辨識；獨立性需依採樣流程判斷。隨機表格列序不適合當作時間獨立性的證據，本報告未宣稱五項假設全部通過。

GPT 輔助內容〔G4、G5〕

05 / Deployment 與自訂資料

GitHub Pages 與瀏覽器分析

網站已發布至 GitHub Pages，透過 GitHub Actions 將 web/dist 靜態檔部署。推送網站檔案或部署設定到 main 會自動更新；Python/scikit-learn 透過 Pyodide 在 Web Worker 內執行，不需要後端推論服務。

https://hitomihuang.github.io/HW2_MULTIPLE_LINEAR_REGRESSION/



圖：資料集切換、自訂 CSV 與分析設定畫面。首次先顯示預先計算示範，點選執行後才實際重新訓練。

操作條件與結果匯出

可輸入公開 CSV URL 或上傳 UTF-8 CSV/TSV，選 Target、排除欄位與分析筆數。互動版上限 10 MB、100 個原始欄位、300 個編碼欄位；有效目標至少 30 筆，分析上限可選 1,000 / 4,000 / 10,000 筆。文字欄超過 40 類或訓練集全空會明示排除。首次需網路載入套件；URL 須允許 CORS，受限時可改用上傳。

可下載 JSON、逐筆預測 CSV 與目前資料集，也能列印結果為 PDF。自訂資料留在瀏覽器；來源、設定、CV、分割列號與逐筆區間均可檢查。

50 Startups：實際執行範例

以 Profit 為目標，4 個原始特徵（含 State）編碼為 5 欄，CV 選入 1 欄；測試 RMSE 7702.2053、R^2 0.926742。為給有限的 95% conformal 區間，至少保留 19 筆校準，本例分為訓練 21 / 校準 19 / 測試 10。測試僅 10 筆，100% 實測覆蓋不可解讀為穩定表現。

GPT 輔助內容〔G3、G6〕

06 / GPT 輔助內容

正文的「GPT 輔助內容」標記，對應以下六組 ChatGPT 問答；G1–G6 的問答截圖收錄於文末。採用的文字已依本專案流程整理。

編號	採用內容	報告位置
G1	CRISP-DM 六階段、訓練／校準／測試分工	資訊圖表、問題定義、資料準備
G2	Pipeline 每折重新 fit；特徵選擇可保留全部欄位	資料準備與建模
G3	CI／PI／conformal 的區分、校準順位與小樣本限制	預測區間、50 Startups 範例
G4	RMSE／R^2 與覆蓋率解讀、共線性與診斷範圍	兩題 Evaluation、模型診斷
G5	隨機表格的獨立性限制、時間／地區／房產群組驗證	資料限制、模型診斷
G6	GitHub Pages、瀏覽器分析、可重現性與 CORS	Deployment 與自訂資料

數值與解釋的來源

樣本數、特徵數、CV 結果、模型誤差與覆蓋率來自本專案資料及程式輸出；GPT 協助方法說明、結果解讀、程式與文件整理。G4 的獨立性建議採納 G5 的適用範圍澄清：隨機表格列序不能當成時間自相關證據。

NotebookLM 研究內容以「NotebookLM 摘要」另行標註，N1–N10 對應其閱讀的網路來源；完整摘要與研究筆記見下一節。

07 / NotebookLM 摘要

本次在 NotebookLM 使用 Fast Research 搜尋同主題解法，匯入三份大學教材，並與 Kaggle 資料及討論、scikit-learn、statsmodels 與 conformal prediction 論文共十份網路來源交叉整理。

NotebookLM 摘要

在 Kaggle 洪水預測競賽中，參賽者假說 20 個特徵為等價偽隨機數，並提出「列總和」與跨欄排序等對稱特徵工程作為候選解法，惟其效果仍須經訓練集交叉驗證，不可斷言已優於原始線性回歸。在資料特性與外推限制上，洪水資料集係由深度學習模型生成的合成資料，分佈僅接近原始資料而非真實觀測；King County 房價則為 2014 至 2015 年的真實歷史房屋交易記錄。若將模型外推至資料範圍之外，預測力將受限。〔N1、N2、N7、N9〕

依據 UBC 與 scikit-learn 指南，標準流程應先切分訓練與測試集，再執行補值、縮放與單熱編碼；需注意 OLS 估計並非必須標準化。為防止資料洩漏，應將 SelectKBest 特徵選擇與模型封裝至 Pipeline 中，使 fit 僅作用於每個 CV 的訓練折，測試集則嚴格保留至最終評估。〔N3、N4、N8、N10〕

在相同 OLS 模型、信賴水準與特徵條件下，平均反應信賴區間僅估計總體均值不確定性，而單一新觀測預測區間因包含個體隨機誤差，範圍必定較寬。若採用 Split-Conformal 預測，雖可提供無分佈假設的保證，但需滿足可交換性且僅限邊際覆蓋。尚待驗證的改進建議，是將對稱特徵工程建構為自訂轉換器併入 Pipeline，透過 CV 嚴格驗證其效益。〔N2、N6、N9〕

NotebookLM 摘要〔N1–N10〕

研究內容在本專案的應用

已採用：以 Pipeline 在訓練折內補值、編碼與特徵選擇；以獨立測試集評估；分別說明 OLS 與 conformal 區間的條件。這些說明已在「資料準備與建模」及「預測區間與模型診斷」旁標註 NotebookLM 摘要來源。

待驗證：將列總和或跨欄排序做為候選特徵工程，再與目前基線比較訓練集 CV 誤差。本報告未把這項網路解法當成已完成的實驗結果。

參考來源與重現資料

[D1] Kaggle：Regression with a Flood Prediction Dataset https://www.kaggle.com/competitions/playground-series-s4e5/data

[D2] Kaggle：House Sales in King County, USA https://www.kaggle.com/datasets/harlfoxem/housesalesprediction

[D3] 50 Startups CSV 範例 https://raw.githubusercontent.com/Avik-Jain/100-Days-Of-ML-Code/master/datasets/50_Startups.csv

[M1] scikit-learn：Common pitfalls and recommended practices https://scikit-learn.org/stable/common_pitfalls.html

[M2] scikit-learn：Feature selection https://scikit-learn.org/stable/modules/feature_selection.html

[M3] statsmodels：OLSResults.get_prediction https://www.statsmodels.org/stable/generated/statsmodels.regression.linear_model.OLSResults.get_prediction.html

[M4] Angelopoulos and Bates：A Gentle Introduction to Conformal Prediction https://arxiv.org/abs/2107.07511

NotebookLM 引用對照

[N1] Kaggle S4E5：官方資料說明 https://www.kaggle.com/competitions/playground-series-s4e5/data

[N2] Kaggle：Sorting along the feature axis as feature engineering https://www.kaggle.com/competitions/playground-series-s4e5/discussion/499579

[N3] scikit-learn：Feature selection https://scikit-learn.org/stable/modules/feature_selection.html

[N4] scikit-learn：Common pitfalls and recommended practices https://scikit-learn.org/stable/common_pitfalls.html

[N5] statsmodels：OLSResults.get_prediction https://www.statsmodels.org/stable/generated/statsmodels.regression.linear_model.OLSResults.get_prediction.html

[N6] Angelopoulos and Bates：A Gentle Introduction to Conformal Prediction https://arxiv.org/abs/2107.07511

[N7] Kaggle：House Sales in King County, USA https://www.kaggle.com/datasets/harlfoxem/housesalesprediction

[N8] UBC CPSC 330：Preprocessing and sklearn pipelines https://ubc-cs.github.io/cpsc330-2024W2/lectures/notes/05_preprocessing-pipelines.html

[N9] BYU Stat 121：Multiple Linear Regression - Prediction https://stat121.byu.edu/Content_in_Quarto/Unit_7_MLR/3_Prediction/LectureNotes/MLR_Prediction.pdf

[N10] University of South Carolina：Multiple Linear Regression https://people.stat.sc.edu/sshen/courses/17smstat509/notes/Chapter%209%20Multiple%20Linear%20Regression.pdf

本機重現

```
python -m pip install -r requirements.txt

python analyze_dataset.py --problem flood

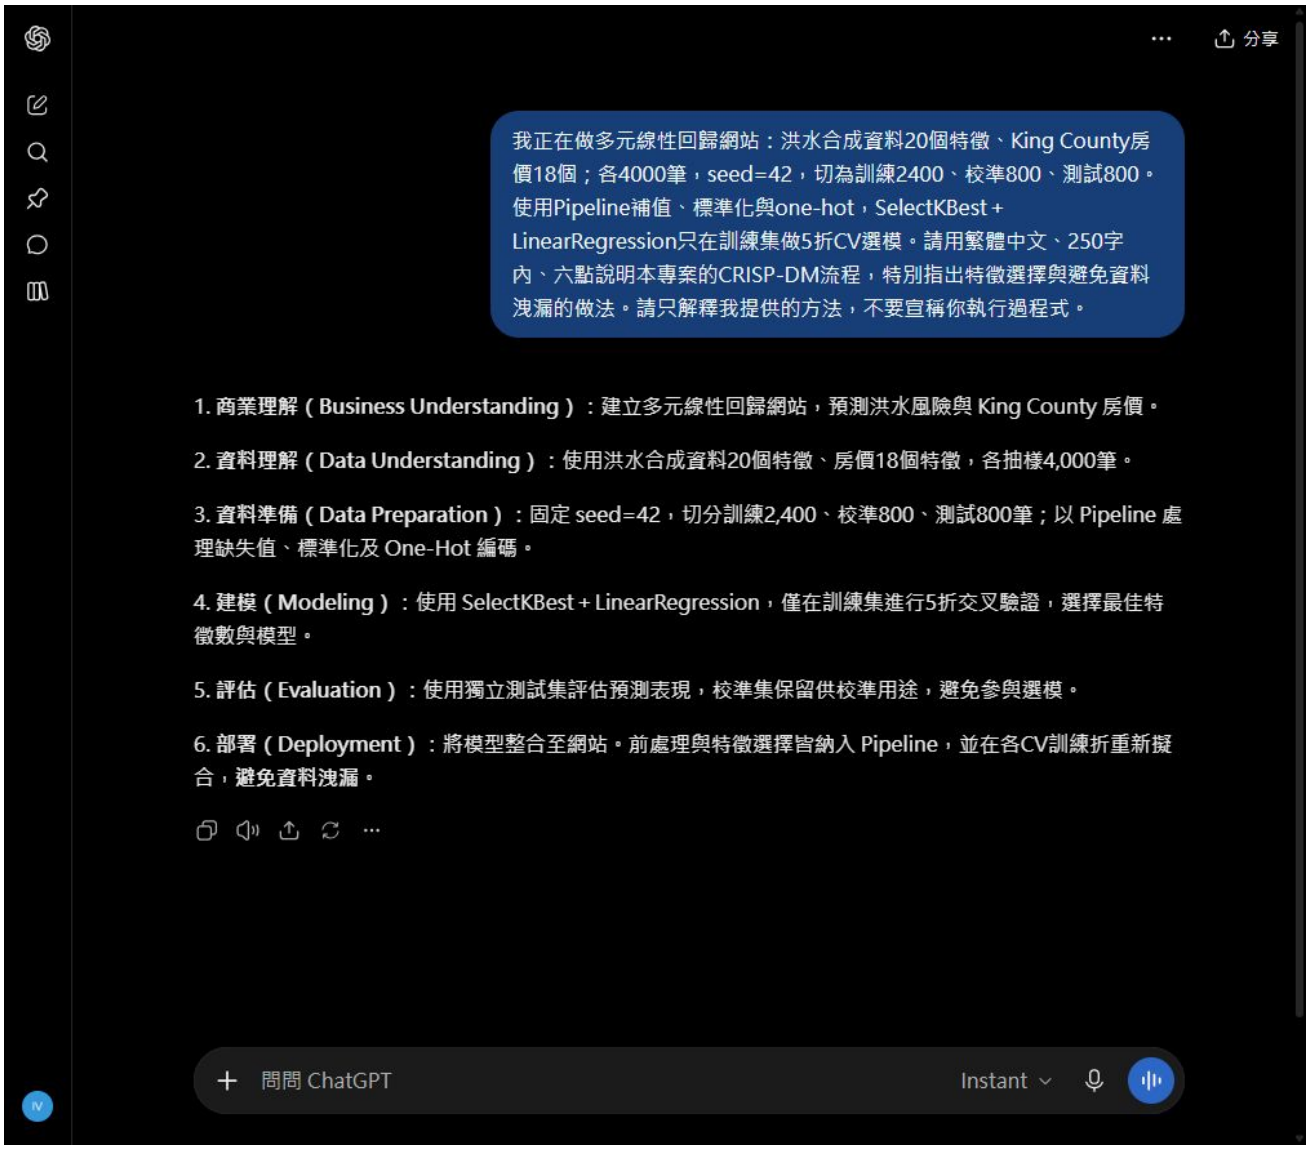
python analyze_dataset.py --problem housing

python analyze_dataset.py --input data/50_Startups.csv --target Profit

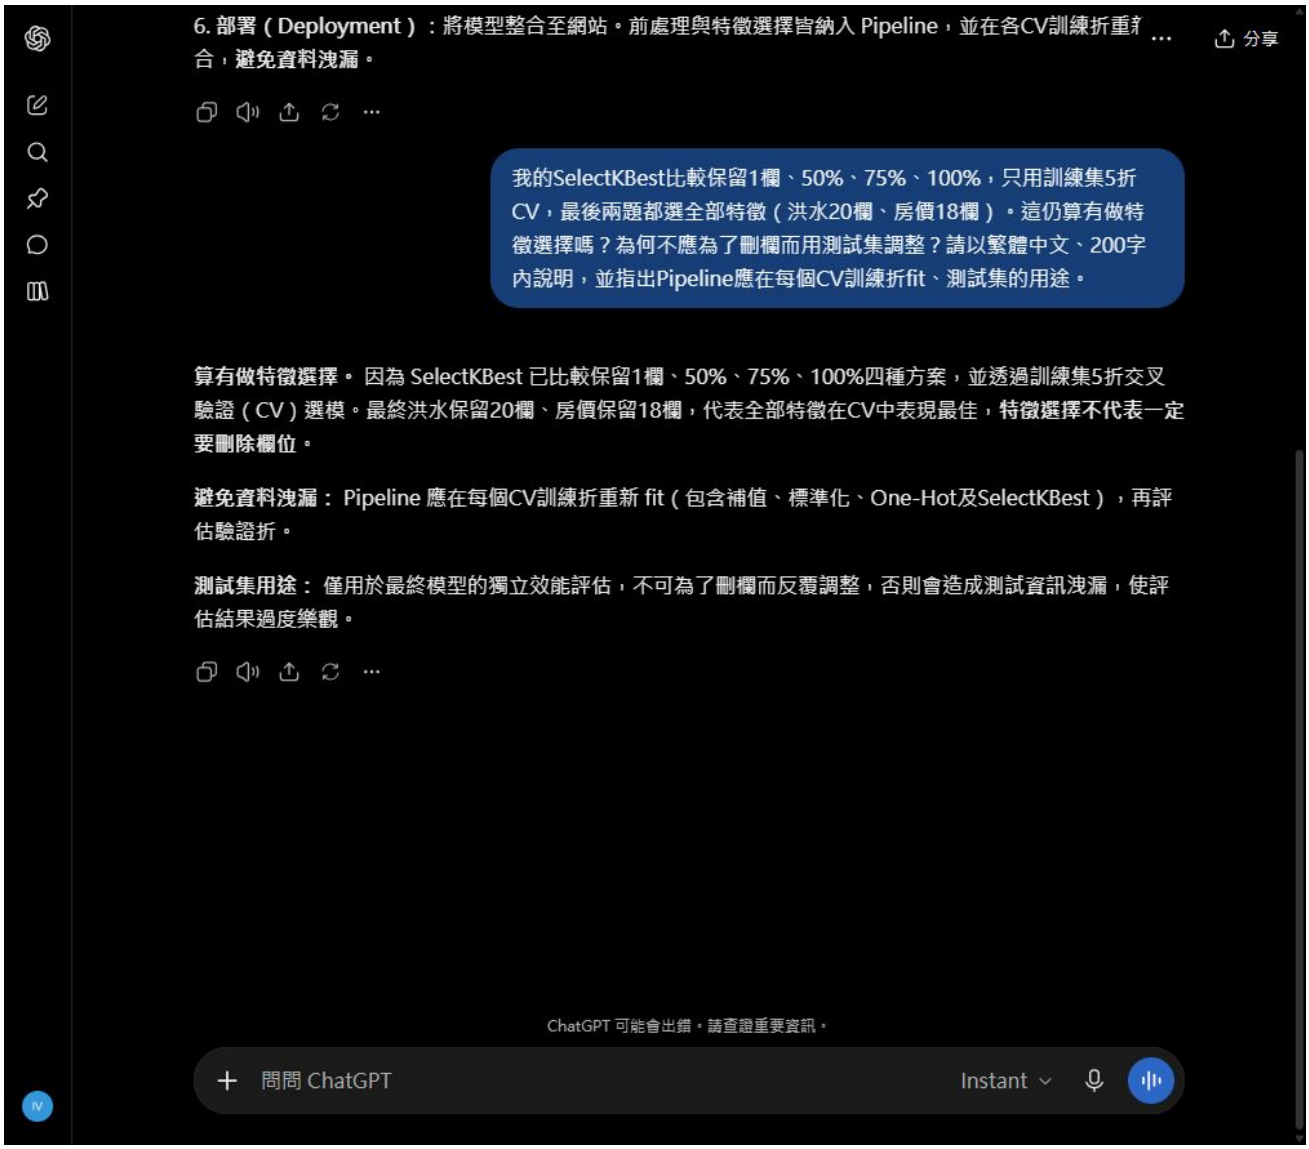
python -m unittest discover -s tests -v
```

主分析引擎：web/dist/analysis.py；網站樣本與示範結果：web/dist/data/；既有數值檢查與部署結果：output/web_validation.json、output/deployment.json。

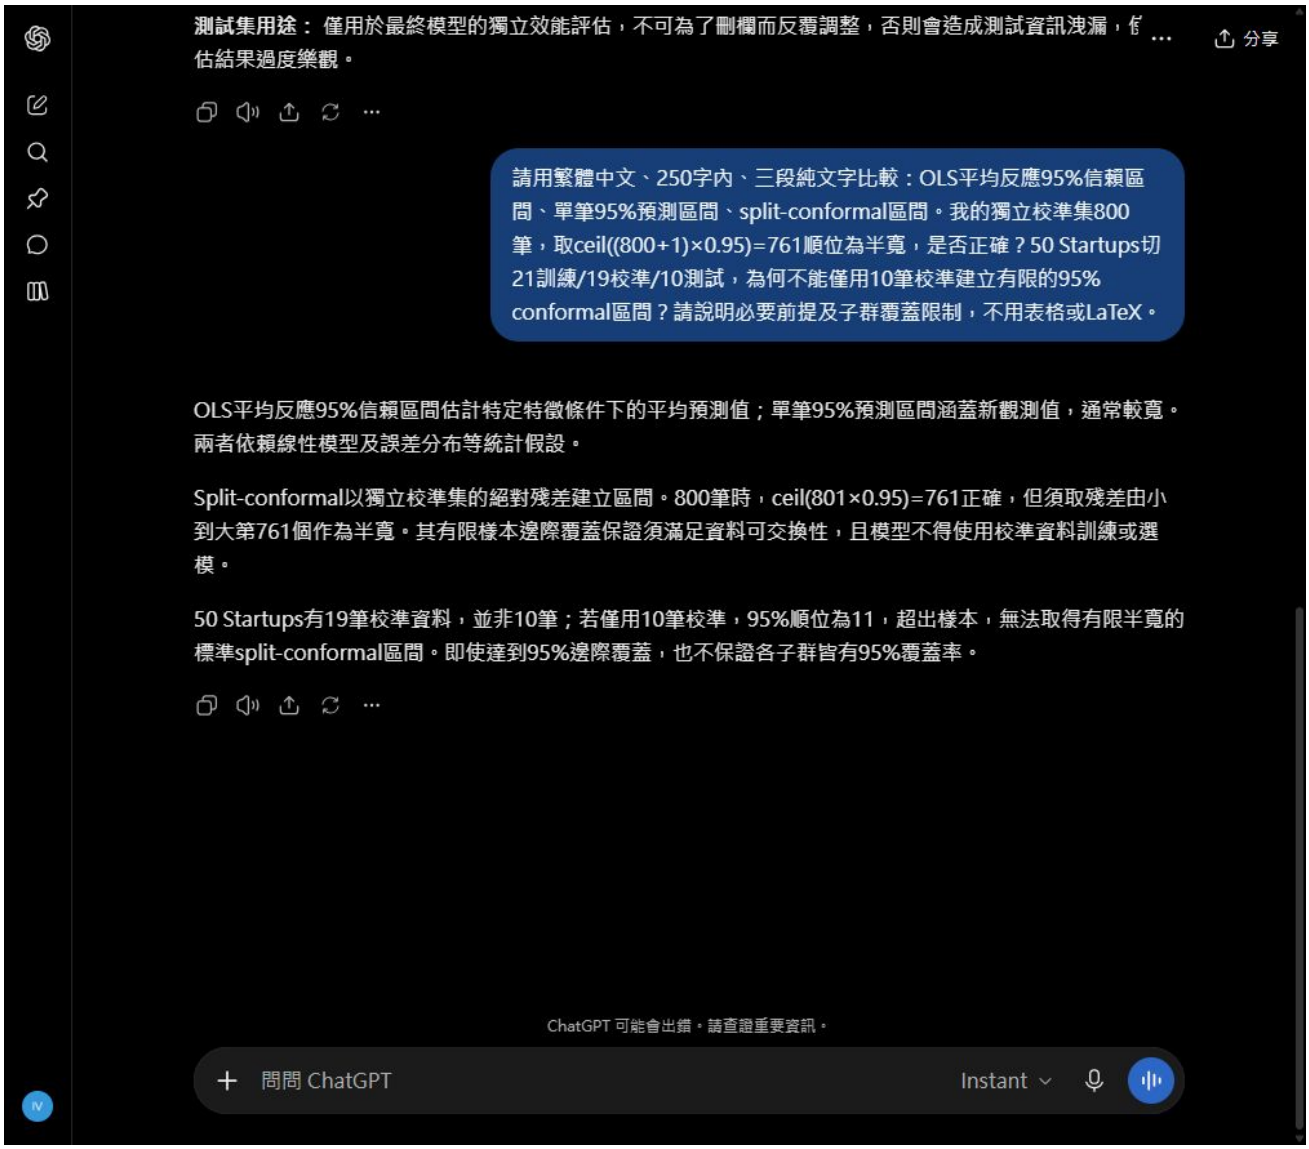
ChatGPT 技術問答 G1｜CRISP-DM 與資料洩漏



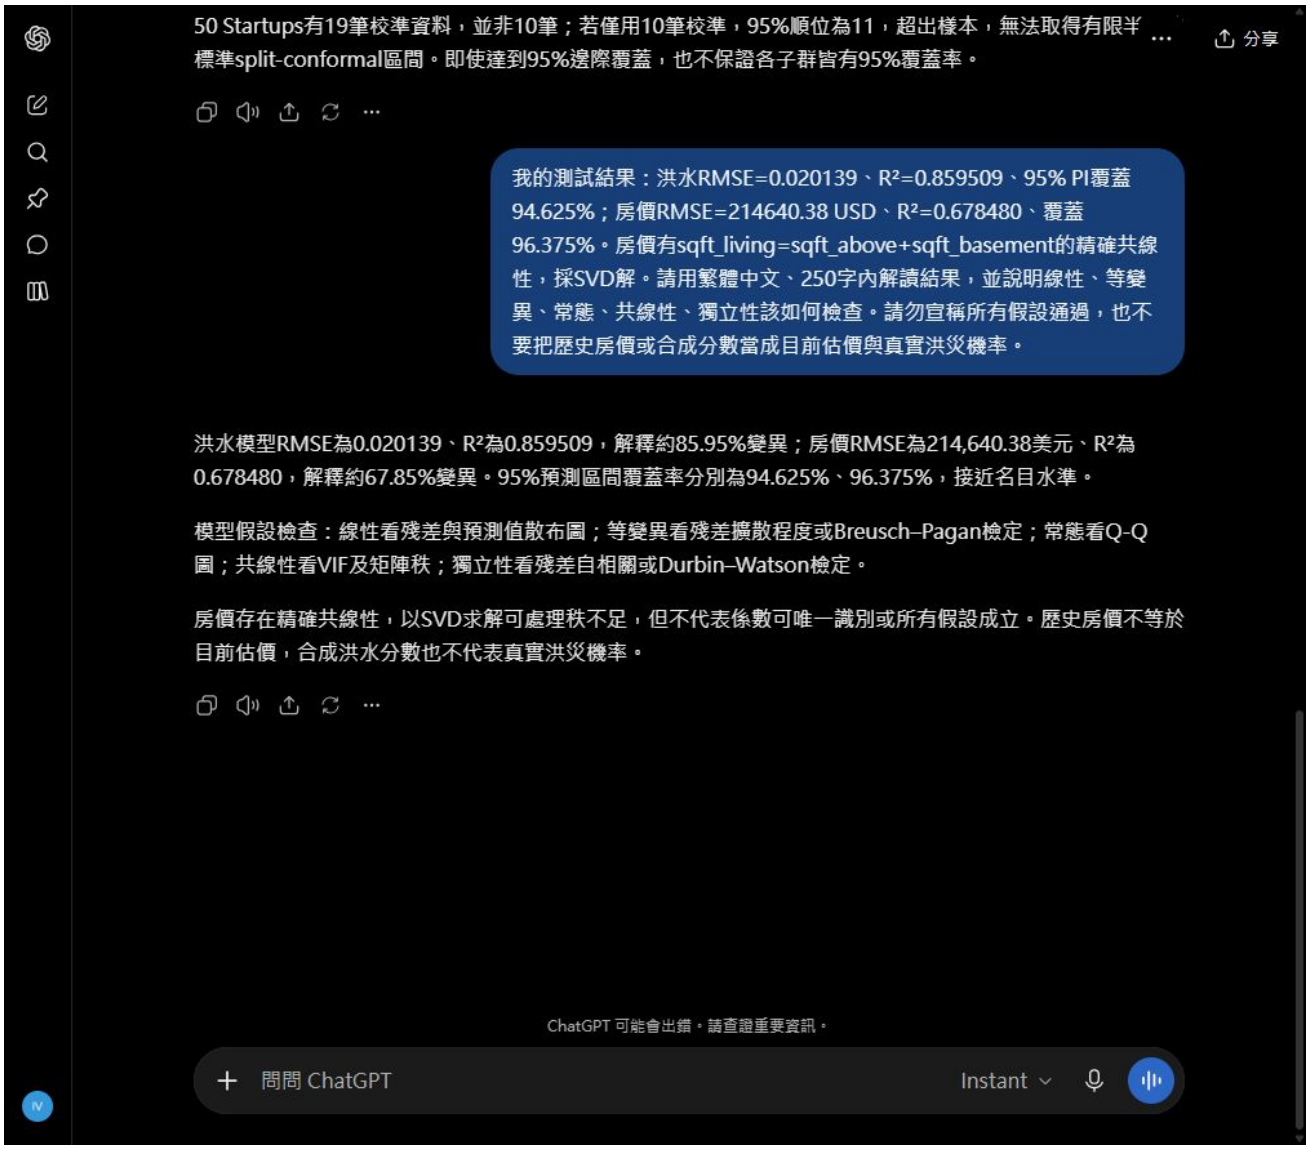
ChatGPT 技術問答 G2｜特徵選擇與交叉驗證



ChatGPT 技術問答 G3｜95% 區間與小樣本校準



ChatGPT 技術問答 G4｜實驗結果與回歸假設



ChatGPT 技術問答 G5｜獨立性與群組泛化評估



ChatGPT 技術問答 G6｜GitHub Pages 部署與可重現性

