多元線性回歸
整合分析報告

Regression Lab

以洪水合成分數與 King County 房價為例，整合資料理解、特徵選擇、線性回歸、獨立測試評估與預測區間，並提供可操作的 GitHub Pages 網站。

分析主題	原始特徵	測試 R^2	95% PI 實測覆蓋
洪水風險分數	20	0.859509	94.625%
King County 房價	18	0.678480	96.375%

網站：https://hitomihuang.github.io/HW2_MULTIPLE_LINEAR_REGRESSION/

GitHub：https://github.com/HitomiHuang/HW2_MULTIPLE_LINEAR_REGRESSION

文件整理時間：2026-11-03 02:24（Asia/Taipei）

內容包含：資訊圖表、CRISP-DM 分析、模型評估與區間圖、GPT 輔助內容、NotebookLM 摘要，以及本次實際在 ChatGPT 網頁取得的六組技術問答截圖。

本報告以網站使用的每題 4,000 筆樣本為主要結果。既有 50,000 筆洪水實驗屬不同資料範圍，其指標不與本報告混用。

內容索引

內容索引 2

資訊圖表｜從資料到預測 3

01 / 問題定義與資料理解 4

02 / 資料準備與建模 5

03 / Evaluation：洪水 6

03 / Evaluation：房價 7

04 / 預測區間與模型診斷 8

05 / Deployment 與自訂資料 9

06 / GPT 輔助內容與 NotebookLM 摘要 10

參考來源與重現資料 11

ChatGPT 技術問答｜實際網頁截圖 12

問答 1｜CRISP-DM 與資料洩漏 13

問答 2｜特徵選擇與交叉驗證 14

問答 3｜95% 區間與小樣本校準 15

問答 4｜實驗結果與回歸假設 16

問答 5｜獨立性與群組泛化評估 17

問答 6｜GitHub Pages 部署與可重現性 18

閱讀方式：先看資訊圖表與兩個題目的評估結果，再查看分析方法與 AI 研究；本次 ChatGPT 技術問答截圖集中於文末。

資訊圖表｜從資料到預測

洪水風險分數

20 個輸入特徵
Target：FloodProbability
合成分數；非真實災害警報

King County 房價

18 個輸入特徵
Target：price（美元）
2014–2015 年歷史交易

每個題目 4,000 筆 | seed = 42

訓練 2,400（60%） | 校準 800（20%） | 測試 800（20%）

01 問題定義

定義數值預測目標與使用限制

02 資料理解

確認來源、輸入特徵與缺失情形

03 資料準備

先切分；補值與編碼只 fit 訓練折

04 建模選擇

五折 CV + SelectKBest + 線性回歸

05 模型評估

獨立測試誤差與 95% 預測區間

06 網站部署

GitHub Pages；自訂 CSV 與結果匯出

洪水模型結果

測試 R^2 = 0.8595
RMSE = 0.020139 （合成分數）
95% PI 實測覆蓋率 94.625%

房價模型結果

測試 R^2 = 0.6785
RMSE = 214,640.38 USD
95% PI 實測覆蓋率 96.375%

每題測試 800 筆。RMSE 的單位不同，兩題不直接比較。95% conformal 區間需要校準與新資料可交換的前提；實測覆蓋不是每個子群的保證。

01 / 問題定義與資料理解

Business Understanding

洪水題目：以 20 個環境與管理分數預測 FloodProbability，研究線性模型是否能擷取合成資料中的規律。此分數未經驗證為真實洪災發生機率，不能作為防災警報。 [D1]

房價題目：以房屋條件、區位與鄰近房產資訊預測 King County 2014–2015 年歷史成交價 price，單位美元；這是歷史交易建模，不代表目前市場估價。 [D2]

Data Understanding

資料集	來源筆數	原始輸入特徵	Target
Kaggle S4E5 洪水	1,117,957	20	FloodProbability
King County 房價	21,613	18	price
50 Startups 範例	50	4	Profit

輸入特徵數不包含 Target、索引、ID 與日期。房價鏡像含額外 CSV 索引，抽樣前移除；兩個內建題目各固定抽取 4,000 筆。50 Startups 僅作自訂 CSV 範例，含 State 類別欄位。 [D3]

洪水樣本 SHA-256：8cb2ee2883f664cdd886872a31e126bbae21c0132618636634446a643d18f231

房價樣本 SHA-256：3a296fdb2b5c7d1d6858df59c16764b4b27ea61801e7a13bbfd60fb3f844b070

資料限制：洪水為合成分數；房價可能有同一房產重複交易、空間依賴與時間差異。來源的資料生成或蒐集背景，會限制可作出的推論。

02 / 資料準備與建模

Data Preparation

固定 seed = 42，每題切為訓練 2,400、校準 800、測試 800。先分割再處理：數值欄以訓練折中位數補值、標準化；類別欄以訓練折眾數補值與 one-hot 編碼。未知類別採忽略處理，預處理與特徵選擇放在 Pipeline 內，測試標籤不參與選模。 [M1]

Modeling 與 Feature Selection

比較平均值基線、全特徵 LinearRegression，以及 SelectKBest + LinearRegression。訓練集五折 CV 比較保留 1 欄、50%、75% 與全部編碼特徵，依平均 CV RMSE 選擇。類別數可能隨折改變，因此保留欄數按各訓練折維度計算。 [M2]

洪水：CV RMSE，單位合成分數

保留比例	最終欄數	平均 CV RMSE	折間 SD
5.0%	1	0.0492594	0.00182912
50.0%	10	0.0391426	0.000893658
75.0%	15	0.0320681	0.000823564
100.0%	20	0.0199308	0.000820978

房價：CV RMSE，單位美元

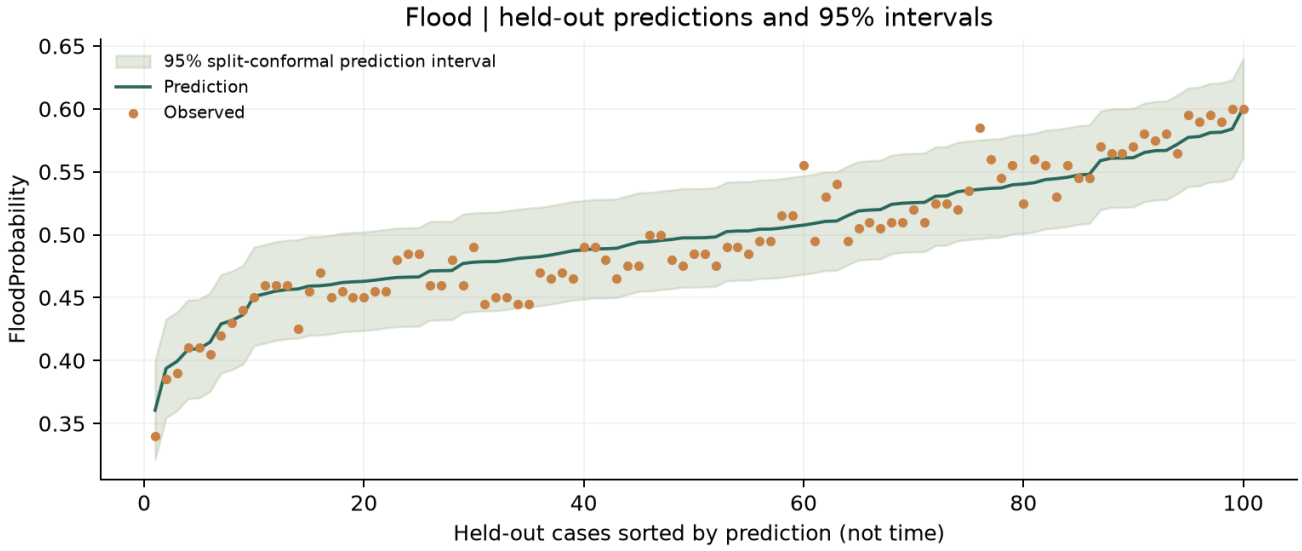
保留比例	最終欄數	平均 CV RMSE	折間 SD
5.6%	1	277412	20128.6
50.0%	9	243289	19009.9
75.0%	14	221926	19625.8
100.0%	18	211276	21530.5

本次候選設定中，兩題都由 CV 選出保留全部特徵。特徵選擇不必然刪欄；本報告如實保留此結果，未依測試集挑選設定。

03 / Evaluation：洪水

模型	MAE	RMSE	R^2
平均值基線	0.043155	0.053731	-0.000047
全特徵 LinearRegression	0.015908	0.020139	0.859509
特徵選擇 LinearRegression	0.015908	0.020139	0.859509

MAE 與 RMSE 單位：合成分數；測試 800 筆。



圖：100 筆固定抽樣測試案例，按預測值排序，橫軸不是時間。綠線為預測，橘點為實際值，陰影為 95% split-conformal 預測區間。完整覆蓋率使用全部 800 筆測試資料計算。

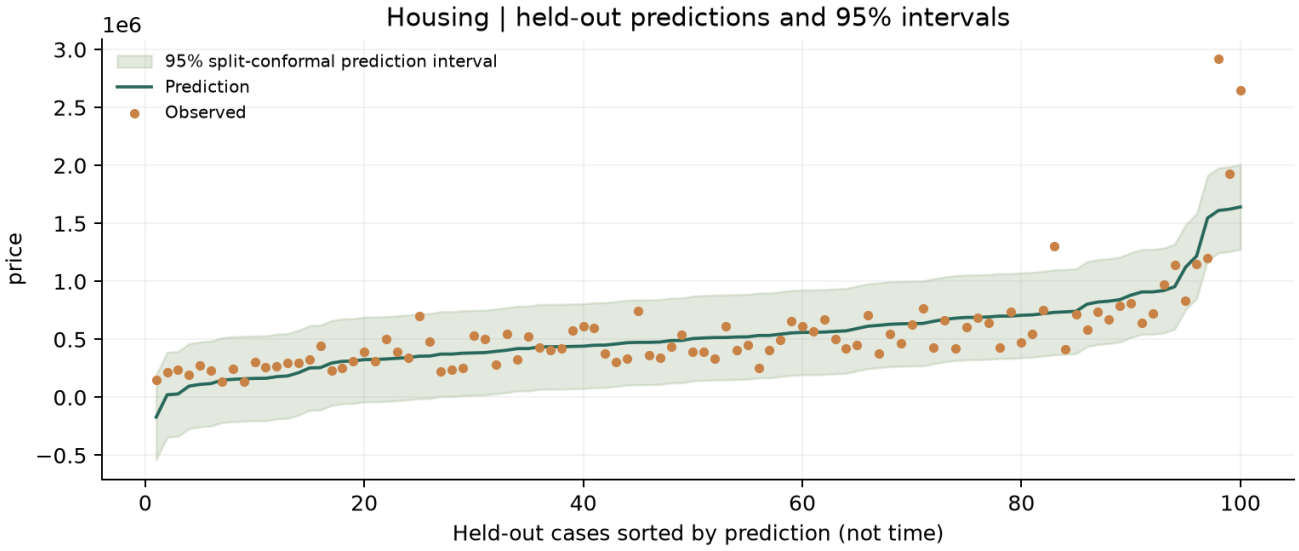
選入 20 / 20 欄。測試 MSE = 0.00040558。調整 R^2 = 0.855902；95% 區間實測覆蓋率 94.625%，平均寬度 0.078333 合成分數。

相較平均值基線，線性回歸降低測試誤差；仍有未被線性模型解釋的雜訊與偏差。這些結果描述本次相似分布樣本，不應直接推廣至真實洪災決策。

03 / Evaluation：房價

模型	MAE	RMSE	R^2
平均值基線	233,396.76	378,547.31	-0.000059
全特徵 LinearRegression	130,199.54	214,640.38	0.678480
特徵選擇 LinearRegression	130,199.54	214,640.38	0.678480

MAE 與 RMSE 單位：USD；測試 800 筆。



圖：100 筆固定抽樣測試案例，按預測值排序，橫軸不是時間。綠線為預測，橘點為實際值，陰影為 95% split-conformal 預測區間。完整覆蓋率使用全部 800 筆測試資料計算。

選入 18 / 18 欄。測試 MSE = 46070492488.41064453 USD^2。調整 R^2 = 0.671070；95% 區間實測覆蓋率 96.375%，平均寬度 731710.033514 USD。

房價偏態與高價離群值使誤差及區間較大。sqft_living = sqft_above + sqft_basement 造成精確共線性，模型採 SVD 最小範數解，個別共線係數不具唯一解。zipcode 的數值表示也是此基線的簡化。跨年份或地區部署需重新評估。

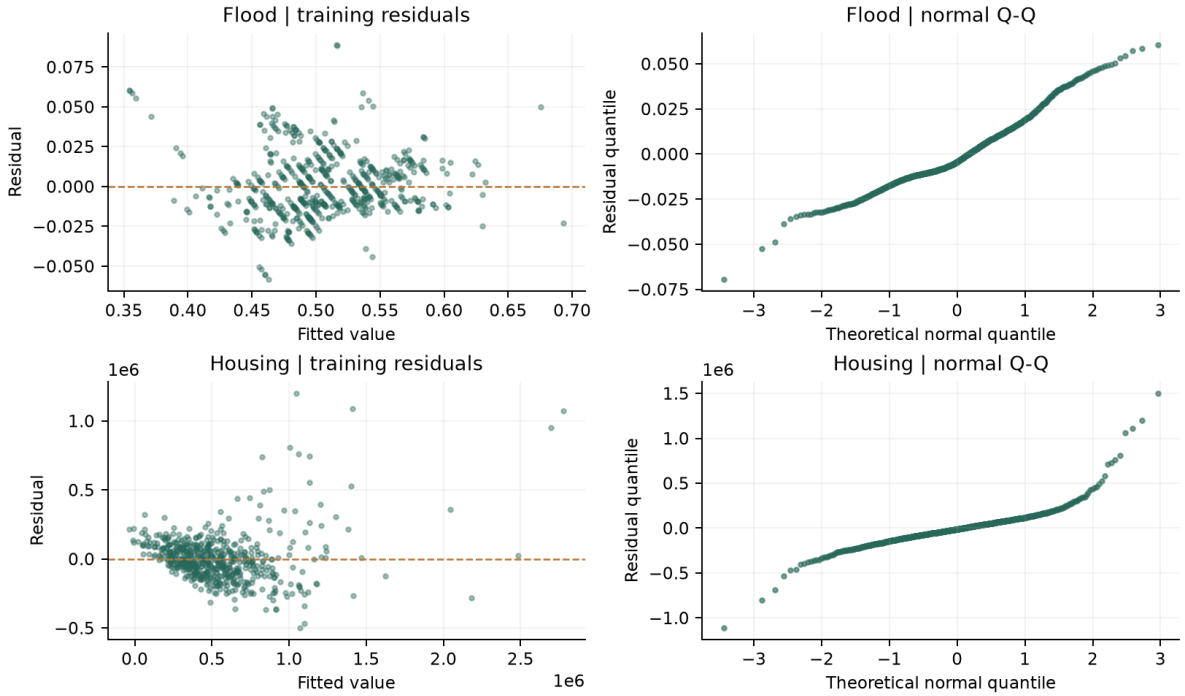
04 / 預測區間與模型診斷

主要區間：95% split-conformal

用獨立校準集的絕對殘差取第 ceil((n_cal + 1) × 0.95) 順位為半寬。800 筆校準取第 761 順位；測試集只評估覆蓋率與誤差，不決定半寬。其邊際覆蓋需要校準與新資料可交換，並不保證每個價位或地區子群都達 95%。區間未裁切上下界。 [M4]

OLS 平均反應信賴區間與單筆預測區間

網站另提供 95% OLS mean CI 與 observation PI，以設計矩陣 SVD 偽逆求 leverage，自由度為訓練筆數減矩陣秩。單筆 PI 多含新觀測的隨機誤差，通常較寬。OLS 區間需額外假設，且未校正選模不確定性，作為參考。 [M3]



上排洪水、下排房價；左圖為訓練殘差，右圖為常態 Q-Q。圖使用固定間隔取出的訓練點。

診斷	洪水	房價
Jarque–Bera p	3.23e-43	小於浮點數顯示範圍
設計矩陣秩 / 欄數	21 / 21	18 / 19
殘差自由度	2,379	2,382

線性與等變異以殘差圖檢視；常態以 Q-Q 與 Jarque–Bera 檢視；共線性以矩陣秩辨識；獨立性需依採樣流程判斷。隨機表格列序不適合當作時間獨立性的證據，本報告未宣稱五項假設全部通過。

05 / Deployment 與自訂資料

GitHub Pages 與瀏覽器分析

網站已發布至 GitHub Pages，透過 GitHub Actions 將 web/dist 靜態檔部署。推送網站檔案或部署設定到 main 會自動更新；Python/scikit-learn 透過 Pyodide 在 Web Worker 內執行，不需要後端推論服務。

https://hitomihuang.github.io/HW2_MULTIPLE_LINEAR_REGRESSION/



圖：資料集切換、自訂 CSV 與分析設定畫面。首次先顯示預先計算示範，點選執行後才實際重新訓練。

操作條件與結果匯出

可輸入公開 CSV URL 或上傳 UTF-8 CSV/TSV，選 Target、排除欄位與分析筆數。互動版上限 10 MB、100 個原始欄位、300 個編碼欄位；有效目標至少 30 筆，分析上限可選 1,000 / 4,000 / 10,000 筆。文字欄超過 40 類或訓練集全空會明示排除。首次需網路載入套件；URL 須允許 CORS，受限時可改用上傳。

可下載 JSON、逐筆預測 CSV 與目前資料集，也能列印結果為 PDF。自訂資料留在瀏覽器；來源、設定、CV、分割列號與逐筆區間均可檢查。

50 Startups：實際執行範例

以 Profit 為目標，4 個原始特徵（含 State）編碼為 5 欄，CV 選入 1 欄；測試 RMSE 7702.2053、R^2 0.926742。為給有限的 95% conformal 區間，至少保留 19 筆校準，本例分為訓練 21 / 校準 19 / 測試 10。測試僅 10 筆，100% 實測覆蓋不可解讀為穩定表現。

06 / GPT 輔助內容與 NotebookLM 摘要

GPT 輔助內容

GPT 協助公開資料研究、Python 與網站程式、特徵選擇與資料洩漏檢查、區間計算、圖表、測試、文件整理，以及 GitHub Pages 部署。模型指標來自實際程式，不由語言模型臆測；係數不作因果詮釋。

NotebookLM 摘要

採用既有於 2026-10-20 實際完成並保存的洪水研究。摘要共 276 個中文字，保留原意與 N1–N6 引用；這不是本次重新生成的 NotebookLM 回覆，也不代表房價結果的研究結論。

Kaggle 洪水分數競賽官方說明，其資料集是由深度學習模型基於「原始資料集」生成的合成資料，分佈僅接近原始資料，非已驗證的真實觀測。〔N1〕Kaggle 討論中，參賽者提出「20 個特徵為等價偽隨機數」之假說，據此建議採用無視順序的列總和與跨欄排序進行對稱特徵工程。〔N2〕

在特徵選擇方面，SelectKBest 依單變量統計檢定篩選，RFE 則依模型權重遞歸剔除〔N3〕；若特徵等價假說成立，特徵選擇未必需要刪欄。〔N2〕為避免資料洩漏，必須嚴格切分訓練與測試集，並透過 scikit-learn 的 Pipeline 將預處理與模型串接，確保 fit 僅作用於訓練集。〔N4〕

估計不確定性時，statsmodels 的 get_prediction 可計算平均反應信賴區間（含模型參數誤差）與單一新觀測預測區間（多含個體隨機誤差而更寬）。〔N5〕若導入符合性預測（Conformal Prediction），其統計保證需滿足校準與新資料的可交換性，以提供無分佈假設的邊際覆蓋。〔N6〕

研究筆記本：https://notebook.google.com/notebook/11cff97a-cbaa-4e58-8eca-b6541d1b25e2

原始證據：notebooklm_raw.txt 保存兩輪提問與回覆，notebooklm_result.json 保存摘要與來源，原 NotebookLM 頁面截圖保存於 output/evidence/notebooklm_research.jpg。

參考來源與重現資料

[D1] Kaggle：Regression with a Flood Prediction Dataset https://www.kaggle.com/competitions/playground-series-s4e5/data

[D2] Kaggle：House Sales in King County, USA https://www.kaggle.com/datasets/harlfoxem/housesalesprediction

[D3] 50 Startups CSV 範例 https://raw.githubusercontent.com/Avik-Jain/100-Days-Of-ML-Code/master/datasets/50_Startups.csv

[M1] scikit-learn：Common pitfalls and recommended practices https://scikit-learn.org/stable/common_pitfalls.html

[M2] scikit-learn：Feature selection https://scikit-learn.org/stable/modules/feature_selection.html

[M3] statsmodels：OLSResults.get_prediction https://www.statsmodels.org/stable/generated/statsmodels.regression.linear_model.OLSResults.get_prediction.html

[M4] Angelopoulos and Bates：A Gentle Introduction to Conformal Prediction https://arxiv.org/abs/2107.07511

NotebookLM 引用對照

[N1] Kaggle S4E5：官方資料說明 https://www.kaggle.com/competitions/playground-series-s4e5/data

[N2] Kaggle：Sorting along the feature axis as feature engineering https://www.kaggle.com/competitions/playground-series-s4e5/discussion/499579

[N3] scikit-learn：Feature selection https://scikit-learn.org/stable/modules/feature_selection.html

[N4] scikit-learn：Common pitfalls and recommended practices https://scikit-learn.org/stable/common_pitfalls.html

[N5] statsmodels：OLSResults.get_prediction https://www.statsmodels.org/stable/generated/statsmodels.regression.linear_model.OLSResults.get_prediction.html

[N6] Angelopoulos and Bates：A Gentle Introduction to Conformal Prediction https://arxiv.org/abs/2107.07511

本機重現

```
python -m pip install -r requirements.txt

python analyze_dataset.py --problem flood

python analyze_dataset.py --problem housing

python analyze_dataset.py --input data/50_Startups.csv --target Profit

python -m unittest discover -s tests -v
```

主分析引擎：web/dist/analysis.py；網站樣本與示範結果：web/dist/data/；既有數值檢查與部署結果：output/web_validation.json、output/deployment.json。

ChatGPT 技術問答｜實際網頁截圖

本章收錄本次在 ChatGPT 網頁實際送出問題、取得完整回答後擷取的畫面。問題根據本專案已完成的資料、流程、實測指標與部署方式提出，包含方法確認與適用範圍的追問。

提問時提供了本專案的實驗設定與數值，ChatGPT 據此解釋方法及結果；這些回覆不是 ChatGPT 另行執行本機程式或 NotebookLM 的驗證紀錄。

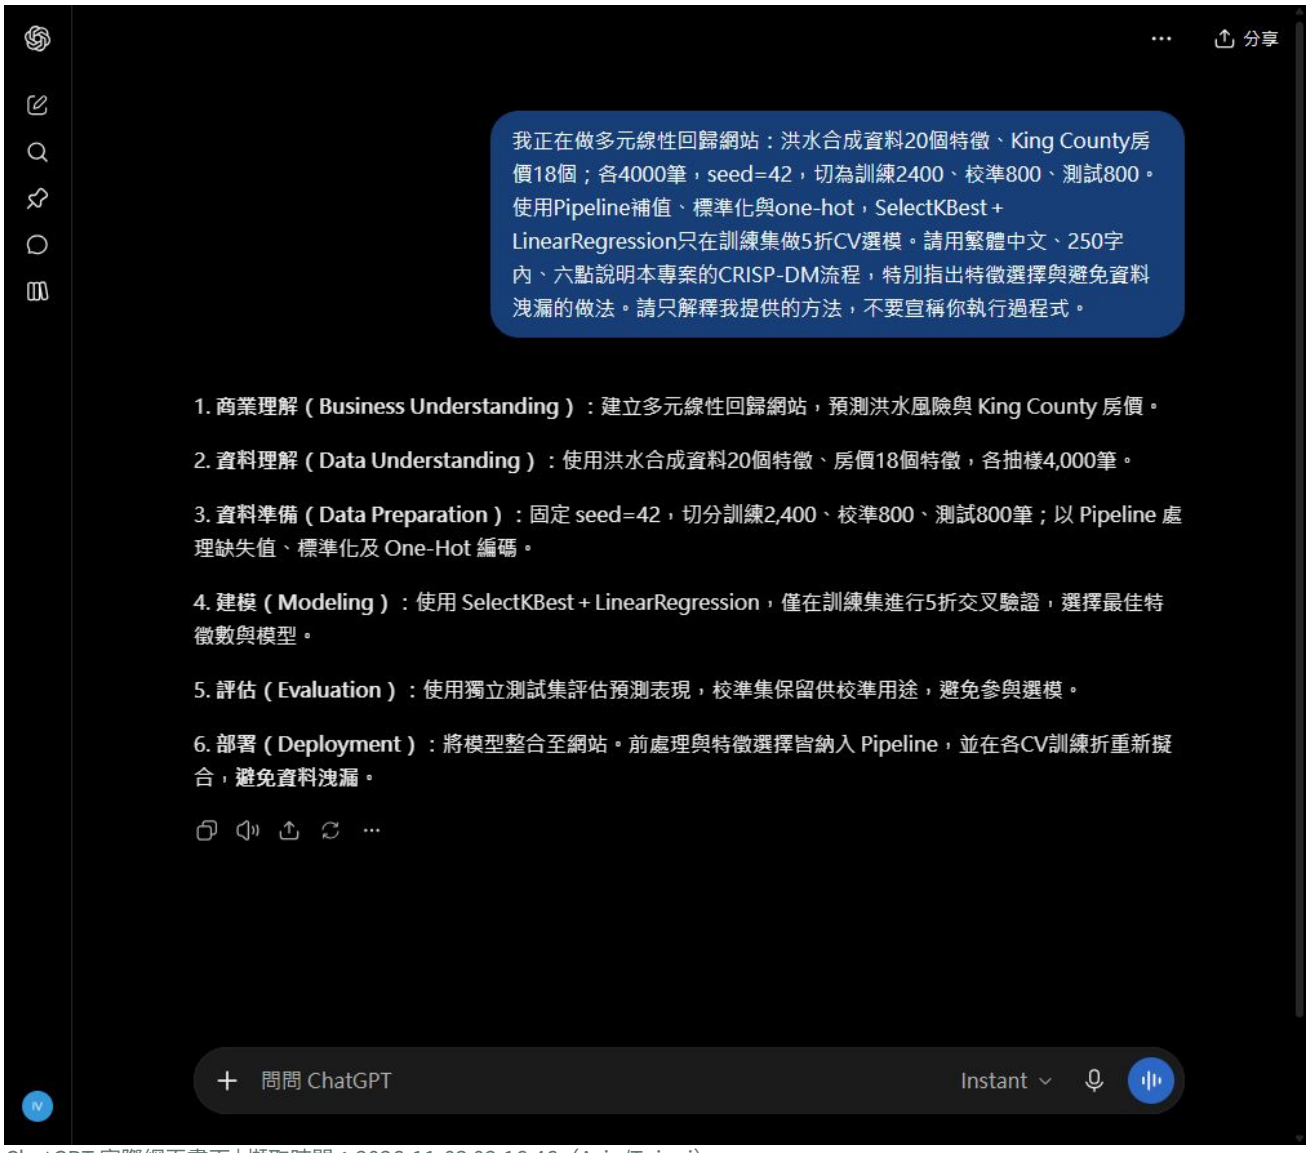
實際對話：https://chatgpt.com/c/6ae8d345-a794-83ee-9b4c-07099bdd0c49

網頁顯示模型：Instant。以下保留原始截圖，不重製或改寫畫面中的回答。

問答	主題
1	CRISP-DM 與資料洩漏
2	特徵選擇與交叉驗證
3	95% 區間與小樣本校準
4	實驗結果與回歸假設
5	獨立性與群組泛化評估
6	GitHub Pages 部署與可重現性

問答 4 的一般獨立性檢查建議，於問答 5 進一步釐清為隨機表格資料、時間及群組切分的適用範圍。閱讀時請一併參照。

問答 1｜CRISP-DM 與資料洩漏



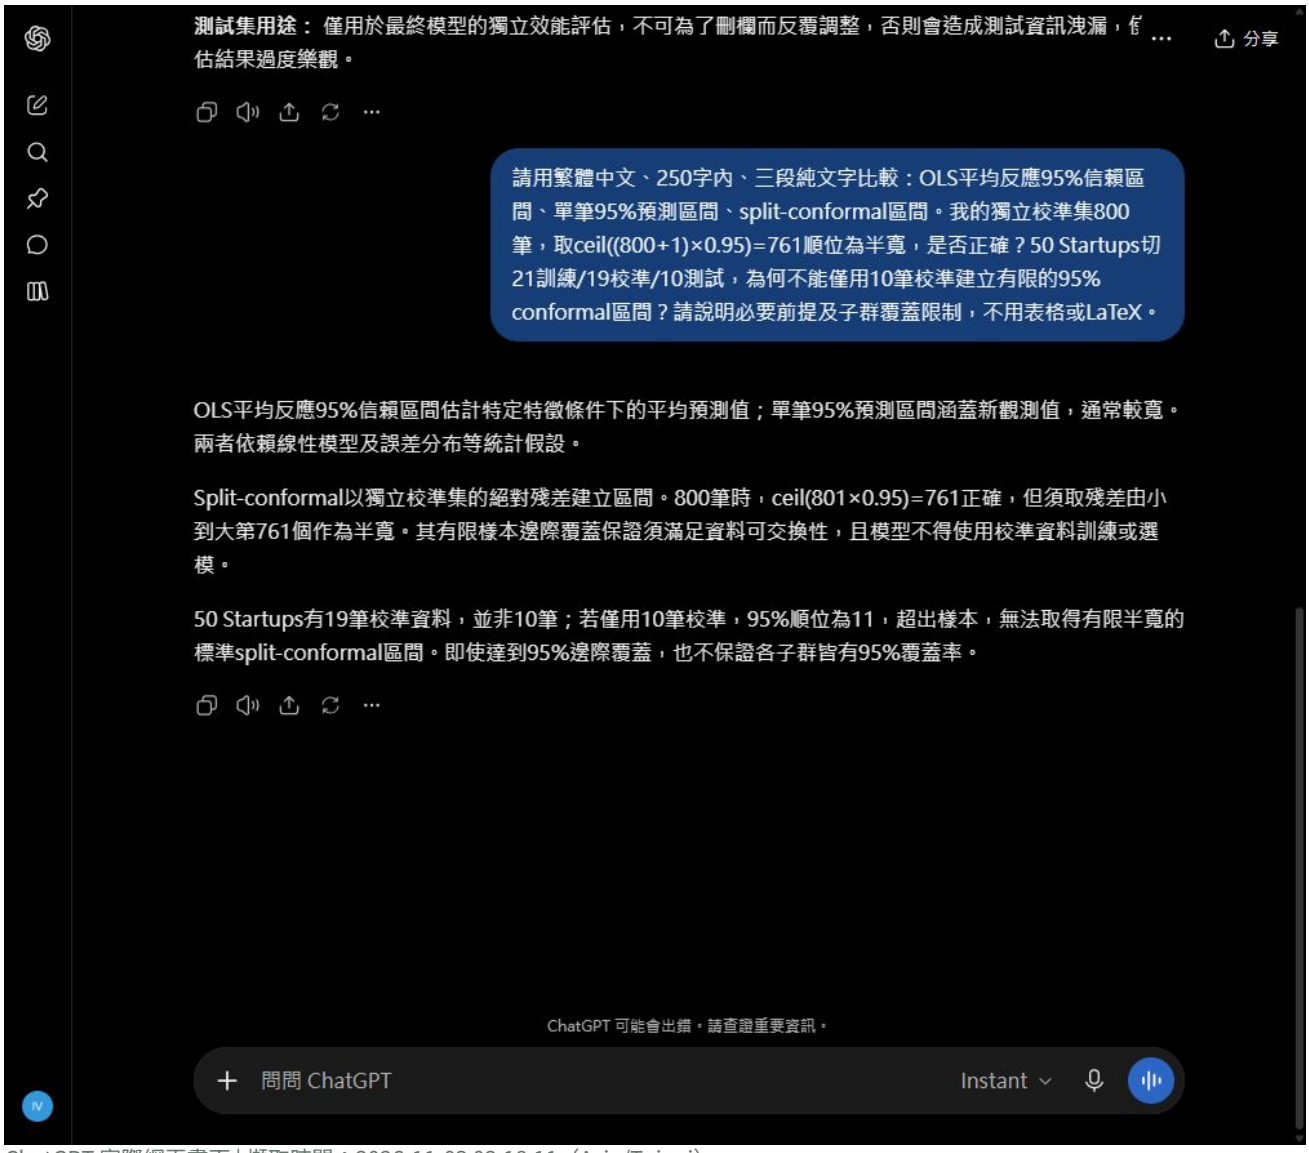
ChatGPT 實際網頁畫面 | 擷取時間：2026-11-03 02:16:46（Asia/Taipei）

問答 2｜特徵選擇與交叉驗證



ChatGPT 實際網頁畫面 | 擷取時間：2026-11-03 02:17:23（Asia/Taipei）

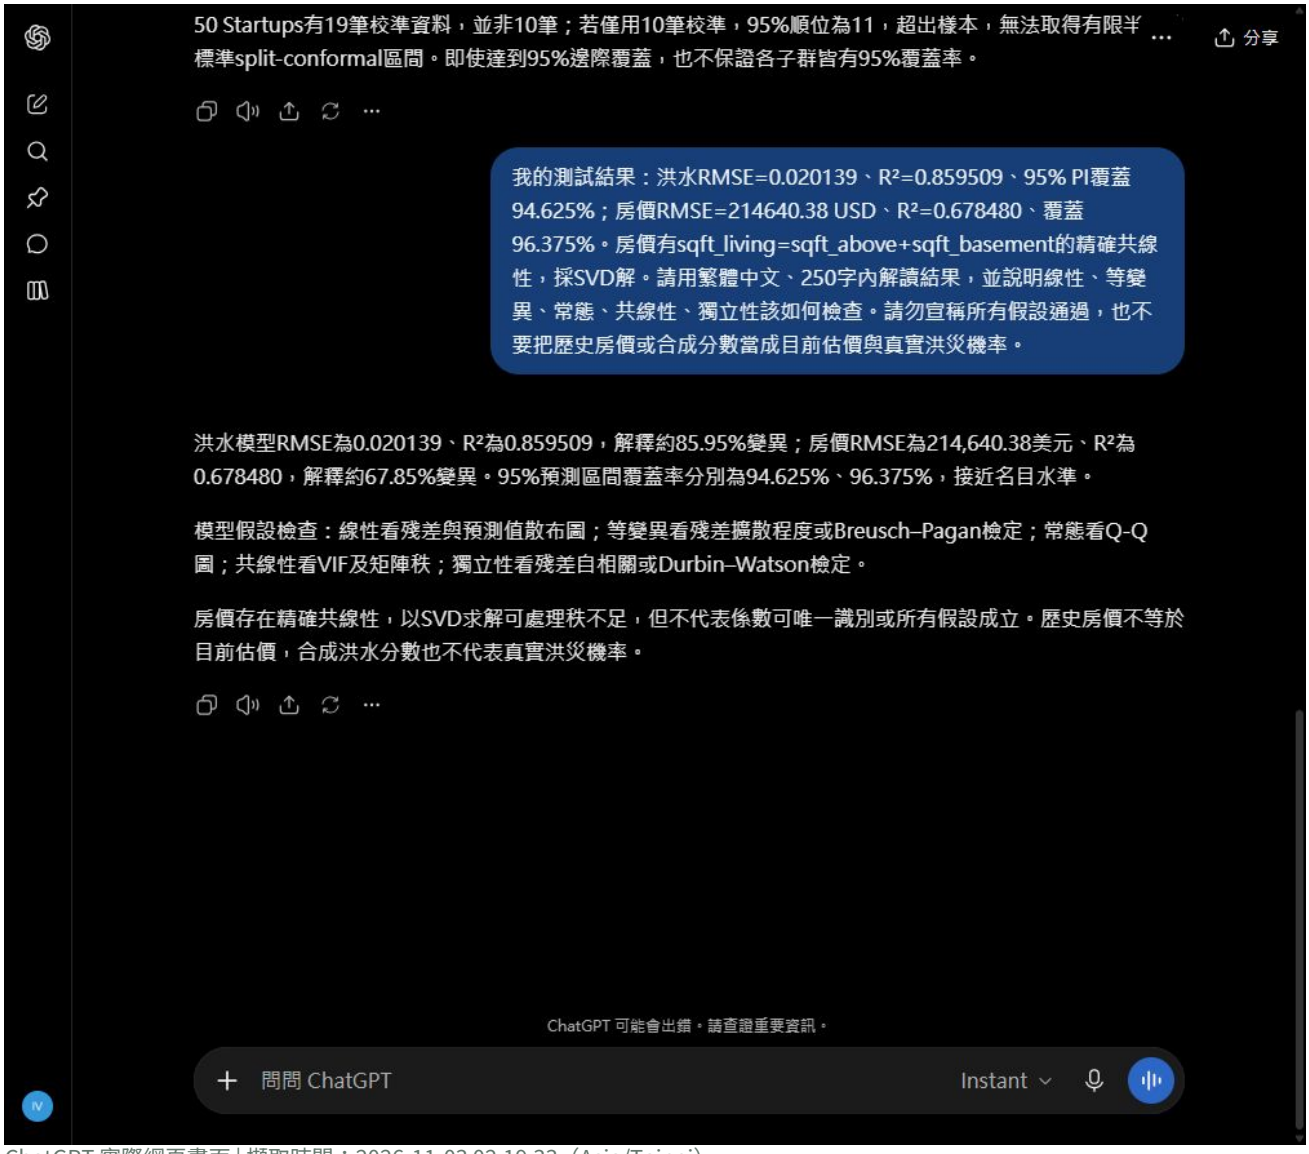
問答 3｜95% 區間與小樣本校準



ChatGPT 實際網頁畫面 | 擷取時間：2026-11-03 02:18:11（Asia/Taipei）

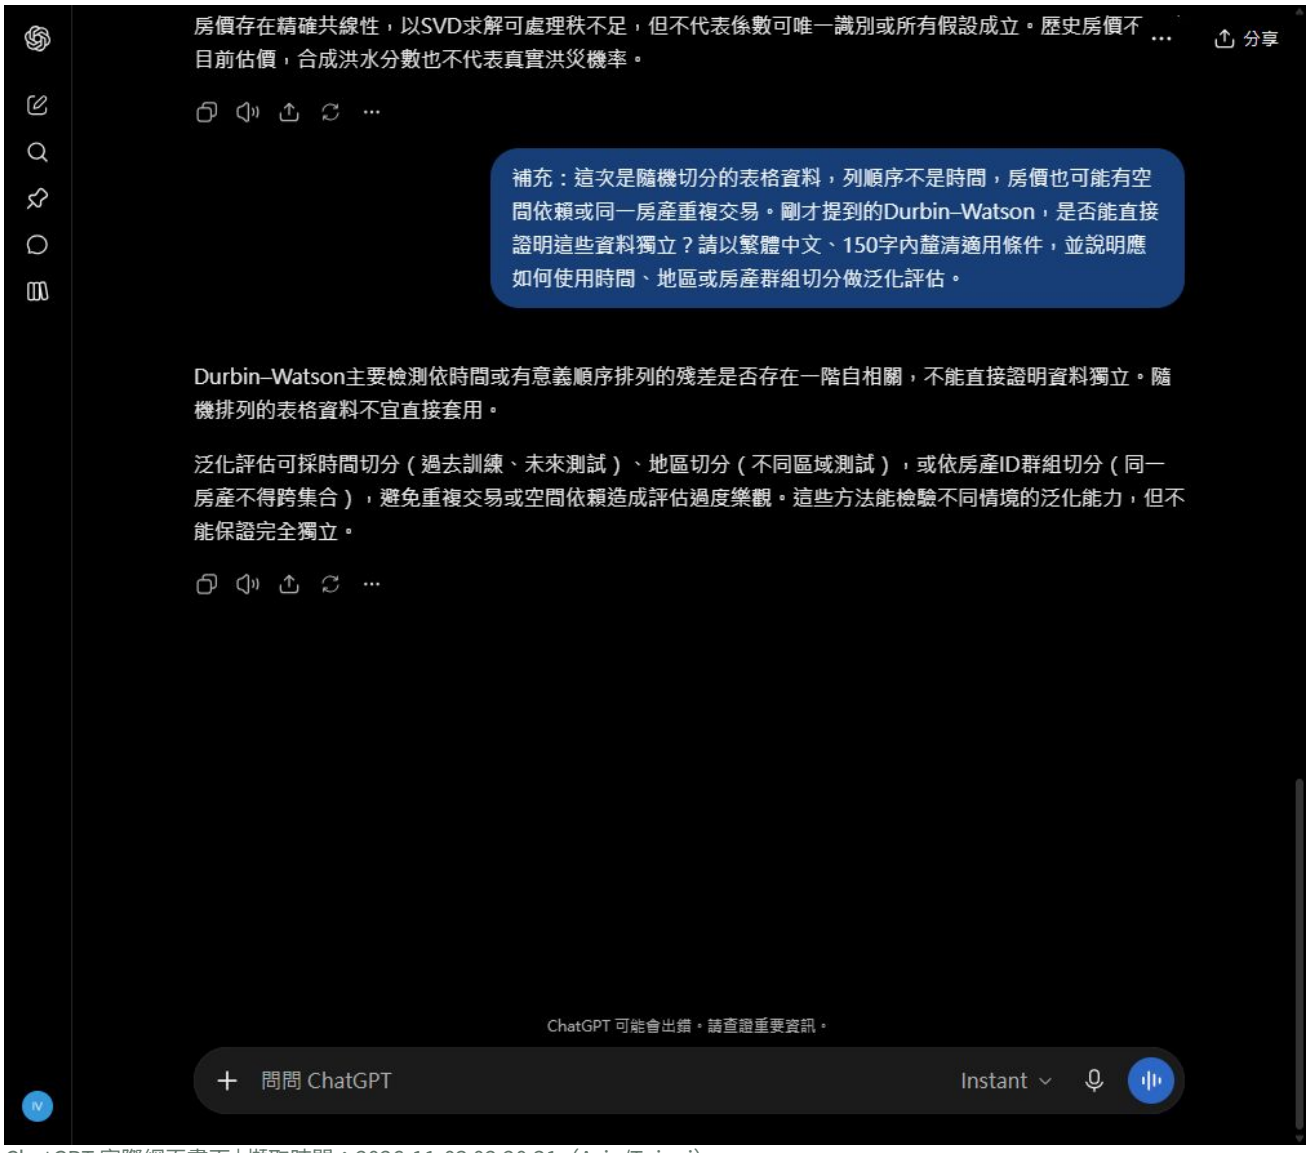
問答 4｜實驗結果與回歸假設

獨立性診斷的適用條件另於下一組問答補充。



ChatGPT 實際網頁畫面 | 擷取時間：2026-11-03 02:19:33（Asia/Taipei）

問答 5｜獨立性與群組泛化評估



ChatGPT 實際網頁畫面 | 擷取時間：2026-11-03 02:20:31（Asia/Taipei）

問答 6｜GitHub Pages 部署與可重現性



ChatGPT 實際網頁畫面 | 擷取時間：2026-11-03 02:21:29（Asia/Taipei）